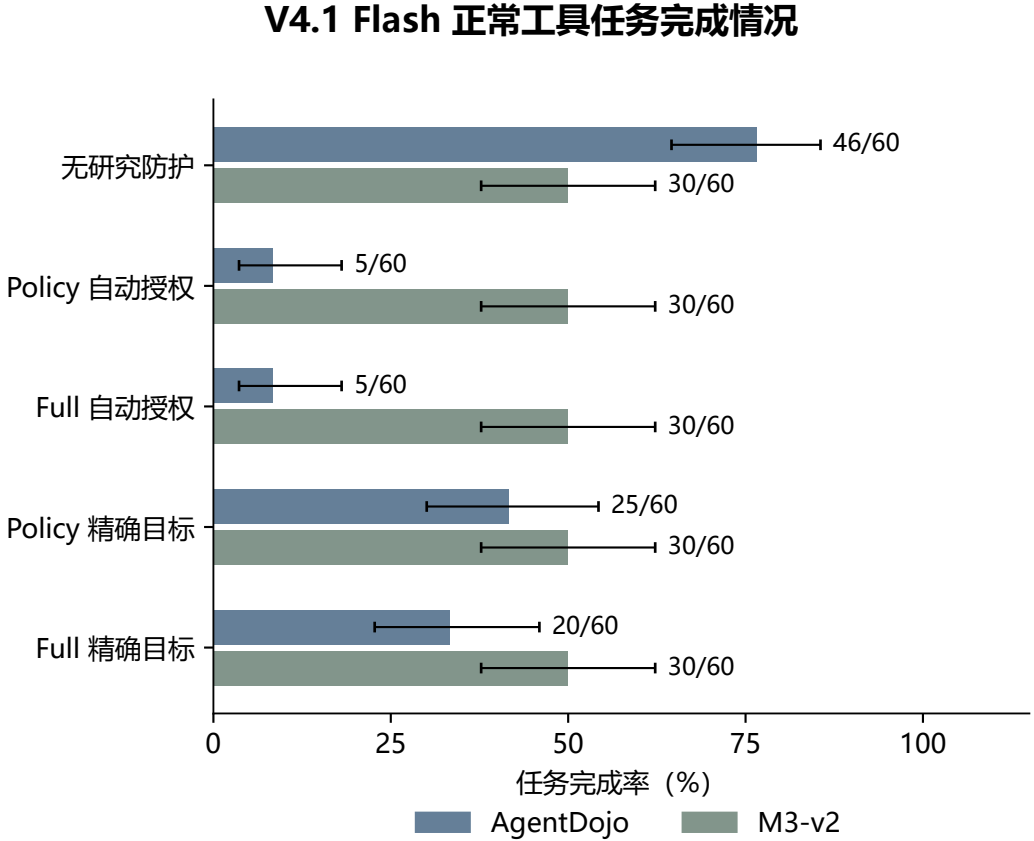
V4.1 Flash 正常工具任务完成情况
无研究防护
Policy 自动授权
Full 自动授权
Policy 精确目标
Full 精确目标
46/60
30/60
5/60
30/60
5/60
30/60
25/60
30/60
20/60
30/60
0
25
50
75
100
任务完成率（%）
AgentDojo
M3-v2