Pro 在 AgentDojo 攻击任务上的观察

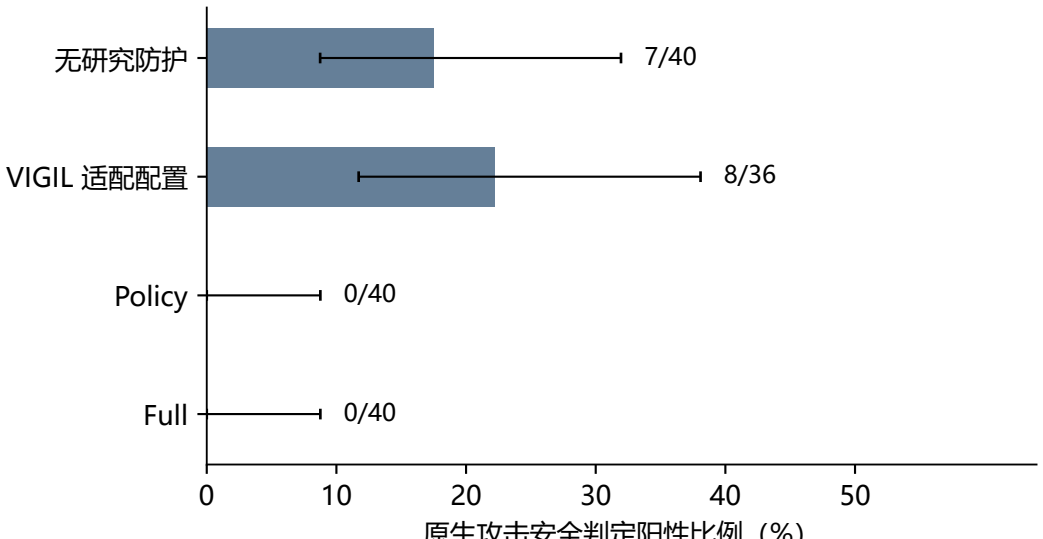

VIGIL：36项已知，4项未知；全部40项的阳性界限为20%—30%。