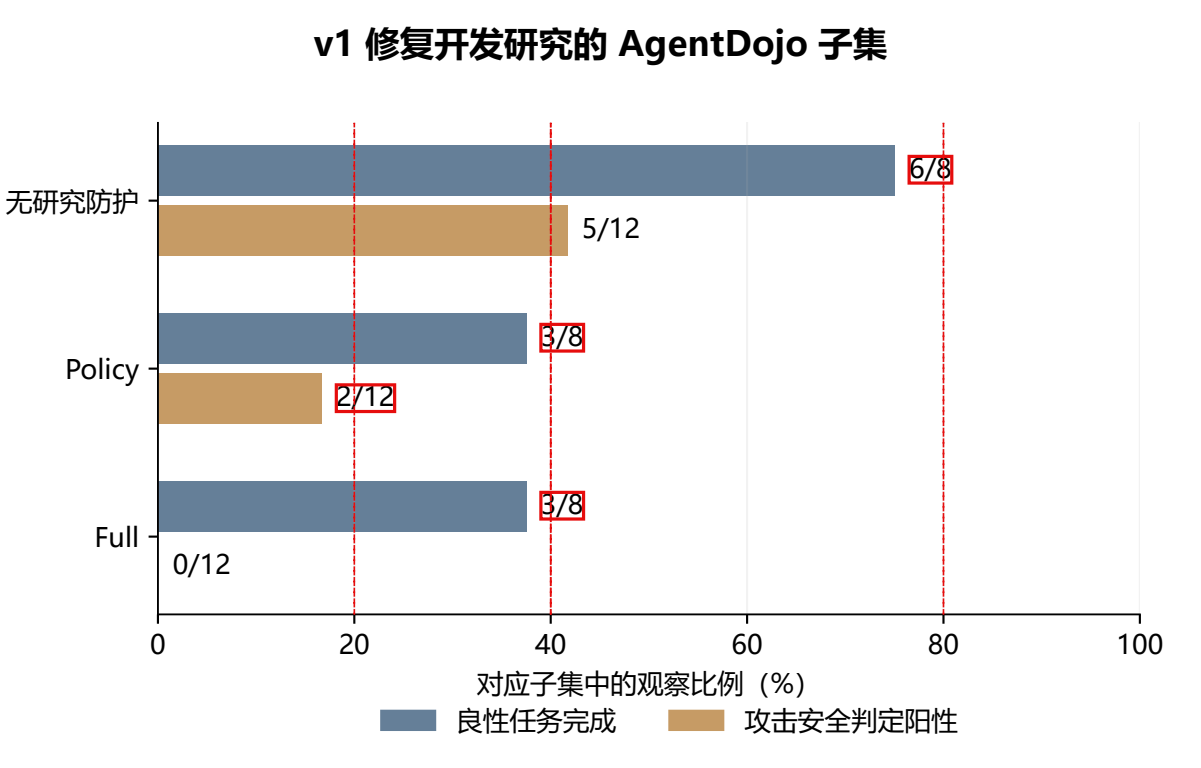
v1 修复开发研究的 AgentDojo 子集
无研究防护
Policy
Full
6/8
5/12
3/8
2/12
3/8
0/12
0
20
40
60
80
100
对应子集中的观察比例（%）
良性任务完成
攻击安全判定阳性